

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: System do analizy i przetwarzania ogłoszeń o pracę i opinii o pracodawcach (na podstawie plików CSV)

Wersja dokumentu: 1.0

Data: 05.06.2026

Autor: Kateryna Verboloz, Karolina Lipińska, Julia Kochelska

1. Wprowadzenie:

Niniejszy dokument stanowi specyfikację wymagań dla skryptu napisanego w języku R, służącego do eksploracji tekstu (Text Mining) oraz analizy wymagań w ofertach pracy z konkretnej branży. System przetwarza dane tekstowe z plików CSV przy użyciu normalizacji i tokenizacji, reprezentując je w przestrzeni wektorowej modelu Bag of Words. W ramach uczenia maszynowego nienadzorowanego narzędzie wykorzystuje algorytm klastrowania k-średnich oraz modelowanie tematów metodą Ukrytej Alokacji Dirichleta (LDA). Efektem działania programu są raporty oraz wizualizacje, obejmujące chmury słów, podział dokumentów na klastry oraz wykresy asocjacji słownych.

2. Cele systemu:

- Wczytanie tekstu wejściowego (plik CSV) z kodowaniem UTF-8.
- Przetwarzanie i oczyszczanie tekstu (normalizacja, tokenizacja, usunięcie stopwords).
- Zliczanie częstości występowania słów oraz ich wizualizacja w formie globalnej chmury słów (model Bag of Words).
- Zastosowanie algorytmów uczenia nienadzorowanego w celu wykrycia ukrytych powiązań między wymaganiami w ofertach pracy.
- Automatyczne grupowanie ogłoszeń i identyfikacja głównych trendów tematycznych w danym sektorze za pomocą algorytmu Ukrytej Alokacji Dirichleta (LDA).
- Zaprezentowanie zebranych statystyk użytkownikowi, w tym generowanie globalnej chmury najpopularniejszych słów kluczowych oraz wykresów analitycznych.

3. Wymagania funkcjonalne:

- **Wczytywanie i wstępna agregacja danych:**
 - Skrypt powinien umożliwiać wczytanie danych tekstowych z lokalnego pliku CSV.
 - Skrypt powinien obsługiwać kodowanie UTF-8.
 - Skrypt powinien usuwać brakujące wartości (NA).
- **Przetwarzanie i oczyszczanie tekstu:**

- Skrypt musi oczyszczać tekst w kolumnie z wymaganiami poprzez: usunięcie adresów URL, wzmianek, linii pionowych, tabulatorów oraz innych zbędnych znaków specjalnych.
- Skrypt musi transformować cały tekst na małe litery.
- Skrypt musi usuwać liczby, interpunkcję oraz nadmiarowe białe znaki.
- Skrypt musi usuwać stopwords oraz zdefiniowaną przez autora listę własnych słów szumowych.

- **Analiza częstości i eksploracja:**

- Skrypt musi generować reprezentację danych w postaci macierzy TDM i DTM (model *Bag of Words*).
- Skrypt musi zliczać i sortować słowa według częstości ich występowania.
- Skrypt musi generować globalną chmurę słów dla najczęściej pojawiających się terminów.

- **Zaawansowana analiza:**

- Skrypt musi umożliwiać automatyczne wykrywanie ukrytych tematów za pomocą algorytmu LDA i generować wykresy najistotniejszych słów dla k tematów.
- Skrypt musi wspierać dobór optymalnej liczby klastrów przy użyciu metody sylwetki (*silhouette method*).
- Skrypt musi dokonywać segmentacji ofert pracy za pomocą algorytmu k-średnich (*k-means*).
- Skrypt musi obliczać współczynnik korelacji Pearsona dla wybranych słów kluczowych w celu znalezienia powiązanych z nimi technologii (analiza asocjacji).

- **Wizualizacja danych:**

- Skrypt musi generować wykresy podziału dokumentów na klastry.
- Skrypt musi generować osobne chmury słów dla każdego wyodrębnionego klastra.
- Skrypt musi prezentować wyniki asocjacji z gradientem natężenia korelacji.
- Skrypt musi prezentować końcowe przypisanie ofert do klastrów.

4. Wymagania нефункциональные:

- **Wydajność:**

- Czas przetwarzania i analizy danych tekstowych (w tym klastrowanie i LDA) dla zbioru do 1000 rekordów nie powinien przekraczać 15 sekund na standardowej stacji roboczej.

- Generowanie interaktywnych tabel i wykresów asocjacji powinno odbywać się w czasie rzeczywistym (poniżej 2 sekund od wywołania funkcji).

- **Bezpieczeństwo:**

- Skrypt musi przetwarzać dane w trybie w pełni lokalnym (*on-premise*), bez wysyłania analizowanych opisów ofert pracy do zewnętrznych API czy chmurowych serwisów firm trzecich.

- **Niezawodność:**

- Skrypt musi być odporny na występowanie pustych rekordów oraz braków danych (NA) w pliku wejściowym.
- Skrypt musi zapewniać stabilność działania algorytmu LDA poprzez automatyczne usuwanie pustych wierszy z macierzy częstości dokumentów (DTM).

- **Użyteczność:**

- Wszystkie generowane wykresy muszą być czytelne, posiadać etykiety osi, tytuły oraz legendy.
- Wizualizacje muszą charakteryzować się spójną estetyką.
- Kolorystyka chmur słów oraz klastrów musi być generowana w oparciu o przyjazne dla oka palety barw.

- **Kompatybilność:**

- Skrypt powinien być kompatybilny z R w wersji 4.5.3 lub nowszej.
- Kod musi poprawnie interpretować znaki diakrytyczne oraz znaki specjalne dzięki wymuszeniu kodowania UTF-8 na poziomie wczytywania pliku.

5. Interfejsy użytkownika:

- **Wejście:**

- Plik tekstowy .csv.

- **Wyjście:**

- Globalna chmura słów oraz dedykowane chmury słów generowane niezależnie dla każdego wyodrębnionego klastra.
- Wykresy kolumnowe przedstawiające tematy wygenerowane przez algorytm LDA, liniowy wykres metody sylwetki do doboru klastrów oraz wizualizacja wykrytych klastrów.

- Wykresy lizakowe prezentujące siłę korelacji Pearsona dla wybranych słów kluczowych.
- Interaktywny raport analityczny w formacie HTML.

6. Wymagania dotyczące danych:

- Skrypt zakłada, że dane tekstowe są w języku angielskim.
- Dane wejściowe muszą znajdować się w pliku o formacie CSV.
- Plik źródłowy musi zawierać nagłówek, w tym kolumnę o nazwie "Requirements".
- Skrypt nie obsługuje plików wejściowych o rozmiarze powyżej 100 MB.

7. Słownictwo dokumentacji:

- **Tokenizacja:** proces podziału ciągłego tekstu na mniejsze, pojedyncze jednostki logiczne w celu ich dalszej analizy.
- **Stopwords:** słowa, które nie wnoszą żadnej wartości semantycznej do analizy.
- **Bag of Words:** model reprezentacji tekstu, w którym dokument jest traktowany jako zbiór pojedynczych słów, z pominięciem zasad gramatycznych oraz kolejności ich występowania, z zachowaniem jedynie informacji o częstotliwości ich pojawiania się.
- **DTM / TDM (Document-Term Matrix / Term-Document Matrix):** struktura danych w formie tabeli, w której wiersze odpowiadają poszczególnym ofertom pracy, a kolumny konkretnym słowom (lub odwrotnie). Wartości w komórkach oznaczają liczbę wystąpień danego słowa w dokumencie.
- **Klastrowanie:** metoda uczenia maszynowego nienadzorowanego, polegająca na automatycznym podziale bazy ofert pracy na podgrupy w taki sposób, aby oferty wewnątrz jednego klastra były jak najbardziej podobne pod kątem wymagań, a oferty z różnych klastrów – jak najbardziej się różniły.
- **Algorytm k-średnich (k-means):** algorytm klastrowania, który dzieli dokumenty na z góry określoną liczbę skupień, dążąc do minimalizacji odległości (matematycznego podobieństwa) między dokumentami a środkiem ciężkości danego klastra.
- **Metoda sylwetki:** technika statystyczna służąca do oceny jakości klastrowania i wyznaczenia optymalnej liczby skupień (k). Mierzy, jak blisko każdego dokumentu znajduje się jego własny klaster w porównaniu do klastrów sąsiednich.
- **LDA (Latent Dirichlet Allocation / Ukryta Alokacja Dirichleta):** model probabilistyczny służący do modelowania tematów.
- **Analiza asocjacji słownych:** badanie statystyczne, które pozwala wykryć, jak silnie dwa słowa są ze sobą powiązane w całym zbiorze danych.

8. Przypadki użycia (use cases)

- Użytkownik:
 - wczytuje plik wejściowy .csv z ofertami pracy.
 - uruchamia analizę.

- wyświetla wygenerowane wyniki.
- przegląda wygenerowane wykresy.
- Skrypt/system:
 - wczytuje i waliduje plik wejściowy (pomija braki danych NA).
 - przetwarza i oczyszcza tekst.
 - filtruje tekst przy użyciu słowników stopwords oraz własnej listy słów.
 - transformuje tekst do macierzy częstości słów (DTM/TDM) i usuwa puste rekordy.
 - generuje globalną chmurę słów.
 - analizuje ukryte tematy dokumentów przy użyciu algorytmu LDA.
 - dzieli oferty na klastry algorytmem k-średnich i generuje chmury słów dla każdego klastra.
 - analizuje asocjacje (korelacje) terminów i generuje wykresy lizakowe.
 - generuje wykresy analityczne.
 - kompiluje wszystkie wyniki.
- **Testowe przypadki użycia:**
 - Test z plikiem .csv zawierającym poprawnie sformatowany tekst ofert pracy w języku angielskim.
 - Test z plikiem .csv zawierającym brakujące wartości (NA) w kolumnie wymagań.
 - Test z plikiem .csv zawierającym znaki specjalne, adresy URL i wzmianki (np. @).
 - Test z plikiem .csv zawierającym tekst składający się wyłącznie ze stopwords.
 - Test z plikiem .csv niezawierającym wymaganej kolumny o nazwie "Requirements".
 - Test z plikiem .csv zawierającym tekst o bardzo rzadko występujących słowach kluczowych.

9. Scenariusze użytkownika (user stories)

Scenariusz 1: Analiza wymagań pracodawców

Jako: Student Informatyki.

Chcę: Zbadać najbardziej pożądane przez pracodawców umiejętności.

Aby: Zrozumieć wymagania rynku pracy i rozwijać kluczowe kompetencje.

Kryteria akceptacji:

- Użytkownik może wczytać plik CSV zawierający treść ogłoszeń o pracę.
- Skrypt automatycznie oczyszcza ogłoszenia ze stopwords oraz zbędnych zwrotów rekruterskich.
- Skrypt generuje globalną chmurę słów, wizualizując technologie, które pojawiają się najczęściej.
- Skrypt oblicza asocjacje terminów, dzięki czemu użytkownik może zobaczyć, jakie technologie najczęściej występują razem.

Scenariusz 2: Sprawdzanie ofert pracy konkurencji

Jako: Specjalista HR

Chcę: Przeanalizować strukturę wymagań w ogłoszeniach konkurencji.

Aby: Zrozumieć z jakich klastrów technologicznych składają się konkretne stanowiska i tworzyć precyzyjniejsze, atrakcyjniejsze oferty pracy.

Kryteria akceptacji:

- Użytkownik dostarcza plik CSV z bazą konkurencyjnych ogłoszeń.
- Skrypt wykorzystuje algorytm modelowania tematów (LDA) do automatycznego wyodrębnienia głównych profili stanowisk.
- Skrypt generuje czytelne wykresy kolumnowe dla każdego z wykrytych tematów, pokazując najważniejsze słowa kluczowe.

Scenariusz 3: Analiza rynku pracy

Jako: Ekonomista

Chcę: Zidentyfikować ukryte trendy technologiczne i dokonać segmentacji ogłoszeń rynkowych.

Aby: Zrozumieć podział rynku pracy i zidentyfikować odrębne dziedziny specjalizacji w danym sektorze.

Kryteria akceptacji:

- Użytkownik może uruchomić system na dużym zbiorze danych wejściowych w formacie CSV.
- Skrypt potrafi podpowiedzieć optymalną liczbę segmentów rynku na podstawie metody sylwetki.
- Skrypt grupuje ogłoszenia algorytmami uczenia nienadzorowanego oraz przypisuje do nich etykiety dokumentów.
- Skrypt generuje odrębne chmury słów dla poszczególnych klastrów, co pozwala analitykowi na łatwe nazwanie rynkowych specjalizacji.
- Skrypt renderuje wykresy lizakowe dla siły korelacji kluczowych technologii.